Relatório técnico do pipeline EEG para Alzheimer no ReDLat

Síntese metodológica e auditoria de integridade a partir do repositório `BrainLat_dataset_Alzheimer_EEG` e do notebook `Pipiline_ML_Alzheimer_3.ipynb`

Relatório elaborado a partir dos materiais fornecidos pelo usuário

***Resumo*—Este relatório descreve, de forma técnica e reprodutível, o pipeline aplicado a dados de EEG do conjunto ReDLat (Argentina e Chile) para classificação de Alzheimer (AD) versus controle saudável (HC). O material analisado inclui o repositório `BrainLat_dataset_Alzheimer_EEG` e o notebook `Pipiline_ML_Alzheimer_3.ipynb`. O fluxo executado compreende: rastreio do funil amostral, seleção de atributos biologicamente motivados, harmonização inter-sítio com neuroCombat, normalização intra-sujeito, benchmark supervisionado com validação Leave-One-Subject-Out (LOSO), testes forenses (permutation test, y-randomization, learning curve e generalização zero-shot entre sítios) e explicabilidade via SHAP. O resultado final reportado no notebook aponta forte separação em Random Forest e XGBoost, desempenho fraco em SVM linear, coerência biológica das principais características espectrais e correlação negativa entre probabilidade prevista de AD e MoCA. Ao mesmo tempo, alguns testes de auditoria sinalizam cautela metodológica, sobretudo a curva de aprendizado saturando cedo e a distribuição de probabilidades muito concentrada em torno de regiões de alta confiança.**

***Index Terms*—EEG, Alzheimer, ReDLat, neuroCombat, SHAP, LOSO, validação cruzada por sujeito, harmonização de sítio**

I. Introdução

O objetivo do pipeline é investigar se padrões de EEG conseguem distinguir AD de HC em um cenário multicêntrico, reduzindo efeitos de sítio e de variabilidade individual. O repositório analisado se apresenta como uma análise em Python de sinais eletrofisiológicos e cognitivos extraídos do `BrainLat_dataset` relacionados à doença de Alzheimer, organizado em etapas como `Analise_Metadados`, `Baixando_Dataset`, `Modelos_ML`, `Preprocessamento` e `pipeline_output_1`. [1], [2]

II. Material analisado

O material de entrada foi composto por dois elementos: (i) o repositório GitHub `BrainLat_dataset_Alzheimer_EEG`, na branch `tiago_rocha`, e (ii) o notebook `Pipiline_ML_Alzheimer_3.ipynb`. O README do repositório descreve o projeto como uma análise em Python de sinais eletrofisiológicos e cognitivos ligados ao Alzheimer. [1]

III. Dados e funil amostral

A primeira etapa do notebook executa um *funnel analysis* para rastrear perdas amostrais entre `features_train.csv` e os metadados. O merge inicial resultou em 53 sujeitos, sem dropout entre as bases. Após o pareamento etário no intervalo de 68 a 82 anos, o conjunto foi reduzido para 40 sujeitos finais, com 8,795 épocas no total. O subconjunto final ficou composto por 23 sujeitos AD e 17 sujeitos HC, com 4,496 épocas AD e 4,299 épocas HC.

Tabela I
Funil amostral e composição final do conjunto

Etapa	Valor
Sujeitos em `features_train.csv`	53
Sujeitos nos metadados	67
Sujeitos após merge interno	53
Dropout entre as bases	0 (0,0%)
Sujeitos após pareamento etário	40
Épocas finais	8,795
Features finais	12
Sujeitos AD / HC	23 / 17
Épocas AD / HC	4,496 / 4,299

As médias etárias após o pareamento ficaram em 76,04 $\pm$ 4,94 anos para AD e 73,71 $\pm$ 3,51 anos para HC, o que reduz parte do viés etário entre classes.

IV. Pré-processamento e blindagem biológica

O notebook adota uma filtragem explícita de variáveis para reduzir dependência de escala e de artefatos instrumentais. Foram removidas 17 variáveis de potência absoluta (`Abs_*`), mantendo 12 atributos considerados biologicamente mais estáveis: medidas relativas (`Rel_*`), razões espectrais (`Razao_*`) e mobilidade de Hjorth. Essa escolha busca preservar a topologia espectral do EEG e minimizar variações associadas a ganho, impedância e referência de montagem.

Tabela II
Atributos preservados no modelo final

Features mantidas	
`Rel_Delta_mean`	`Rel_Delta_std`
`Rel_Theta_mean`	`Rel_Theta_std`
`Rel_Alpha_mean`	`Rel_Alpha_std`
`Rel_Beta_mean`	`Rel_Beta_std`
`Razao_Theta_Alpha`	`Razao_Delta_Alpha`
`Razao_SlowFast`	`Hjorth_Mobilidade`

Em seguida, foi aplicada harmonização com neuroCombat para remover efeito de sítio entre Argentina (`AR`) e Chile (`CL`).

O procedimento segue a lógica do ComBat/empirical Bayes proposta por Johnson et al., preservando a variância biológica enquanto ajusta diferenças de batch. [3]

Depois disso, o notebook executa z-score intra-sujeito, normalizando cada feature dentro de cada indivíduo. Essa etapa reduz diferenças absolutas entre sujeitos e enfatiza a variação temporal/relativa dentro de cada registro.

V. Modelagem supervisionada

O benchmarking comparou três famílias de modelos: Random Forest, SVM linear e XGBoost. A avaliação foi feita em LOSO (*Leave-One-Subject-Out*), de modo que nenhuma época do sujeito de teste apareça no treino. As probabilidades por época foram agregadas por sujeito, produzindo métricas mais realistas em nível clínico.

Tabela III
Benchmark LOSO por sujeito

Modelo	AUC	Sens.	Esp.	F1
Random Forest	1,0000	1,0000	1,0000	1,0000
SVM linear	0,2302	0,4783	0,2353	0,4681
XGBoost	0,9949	0,9130	0,9412	0,9333

Os resultados indicam que Random Forest e XGBoost capturam fortemente a separação AD vs HC, enquanto o SVM linear não se ajusta adequadamente ao espaço de atributos construído. O notebook seleciona o Random Forest como modelo vencedor, porém os próprios testes adicionais sugerem cautela na interpretação de desempenho perfeito.

VI. Auditoria forense do pipeline

Para verificar robustez e evitar leitura excessivamente otimista, o notebook aplica quatro auditorias principais.

A. Permutation test

Foi executado um permutation test com 100 permutações usando `StratifiedGroupKFold(5)`. O resultado reportado foi AUC real de 0,8890, média nula de 0,8890 e $p = 1{,}0000$. Esse comportamento levou o próprio notebook a marcar a hipótese nula como não rejeitada, sinalizando possível presença de padrões espúrios ou limitação metodológica na implementação do teste.

B. Y-randomization

A randomização dos rótulos produziu AUC médio nulo de 0,4956, muito próximo do acaso. Esse é um indicativo positivo de que o pipeline não está apenas aprendendo sinal puramente aleatório.

C. Learning curve

A curva de aprendizado mostrou AUC de 0,8800 com 10 sujeitos e saturação para valores próximos de 1,0 a partir de 15–25 sujeitos. Embora a monotonicidade seja coerente com ganho de informação amostral, a saturação muito precoce reforça a necessidade de cautela quanto à memorização de identidades individuais.

D. Generalização cross-site zero-shot

O teste bidirecional entre sítios apresentou AUC de 1,0000 tanto em CL $\rightarrow$ AR quanto em AR $\rightarrow$ CL. Em termos operacionais, isso sugere forte transferência entre sítios; no entanto, resultados tão elevados em um problema clínico multicêntrico também exigem revisão crítica de possíveis confundidores não biológicos.

Tabela IV
Auditorias forenses adicionais

Teste	Resultado	Interpretaçã
Permutation test	AUC real 0,8890; $p = 1{,}0000$	Não rejeita
Y-randomization	AUC 0,4956	Compatível
Cross-site CL$\rightarrow$AR	AUC 1,0000	Generalizaçã
Cross-site AR$\rightarrow$CL	AUC 1,0000	Generalizaçã
Learning curve	0,88 $\rightarrow$ 1,00	Saturação p

VII. Explicabilidade e validade biológica

A interpretação global com SHAP mostrou que as features mais importantes são `Razao_Theta_Alpha`, `Rel_Alpha_mean`, `Rel_Theta_mean`, `Razao_Delta_Alpha`, `Razao_SlowFast` e `Rel_Delta_mean`. O notebook reporta consonância 3/3 entre as três features mais relevantes e a literatura de *brain slowing*. A atribuição SHAP segue a formulação original de Lundberg e Lee. [4]

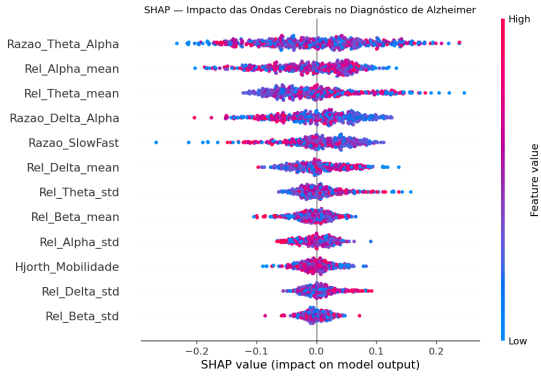

Figura 1. Resumo SHAP global. As features espectrais relativas e as razões entre bandas dominam a explicação do modelo.

Além disso, a distribuição das probabilidades preditas mostrou grande concentração: o Random Forest exibiu 86,2% de amostras na zona cinzenta e o SVM 100,0%. Em um contexto clínico, isso indica que o conjunto apresenta sobreposição substancial nas probabilidades estimadas, e que o desempenho muito alto não deve ser lido sem auditoria adicional.

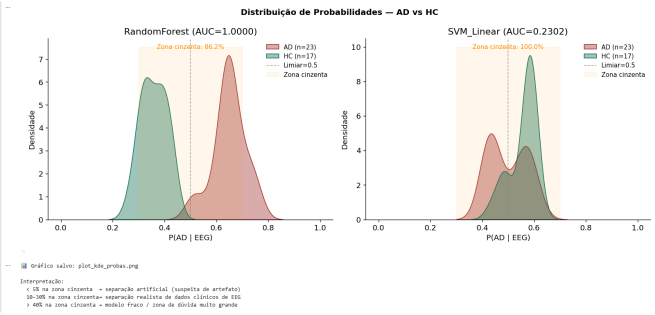

Figura 2. Distribuição de probabilidades previstas para AD versus HC. A região cinzenta entre 0,3 e 0,7 foi usada como referência de incerteza.

A correlação entre $P(\mathrm{AD})$ e MoCA foi negativa, com Spearman $r = -0{,}5245$ e $p = 0{,}0025$ em 31 sujeitos com o escore disponível. Esse resultado é coerente com um gradiente clínico real: menores escores cognitivos associam-se a maior probabilidade estimada de AD.

VIII. Relatório final de integridade

O notebook encerra com uma auditoria consolidada. O resumo final reporta 8 passos aprovados, 2 *warnings* e nenhum *fail*. O quadro geral indica que a pipeline foi considerada "aprovada" pelo próprio notebook, mas com alertas importantes em LOSO e permutation test.

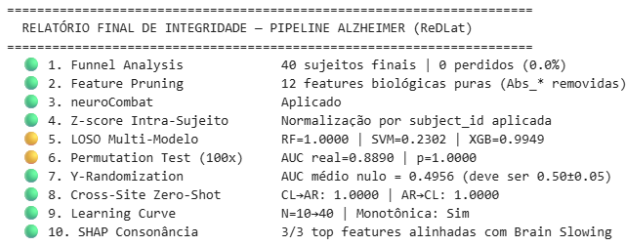

```
======================================================================
  RELATÓRIO FINAL DE INTEGRIDADE — PIPELINE ALZHEIMER (ReDLat)
======================================================================
  🟢 1. Funnel Analysis            40 sujeitos finais | 0 perdidos (0.0%)
  🟢 2. Feature Pruning            12 features biológicas puras (Abs_* removidas)
  🟢 3. neuroCombat                Aplicado
  🟢 4. Z-score Intra-Sujeito      Normalização por subject_id aplicada
  🟡 5. LOSO Multi-Modelo          RF=1.0000 | SVM=0.2302 | XGB=0.9949
  🟡 6. Permutation Test (100x)    AUC real=0.8890 | p=1.0000
  🟢 7. Y-Randomization            AUC médio nulo = 0.4956 (deve ser 0.50±0.05)
  🟢 8. Cross-Site Zero-Shot       CL→AR: 1.0000 | AR→CL: 1.0000
  🟢 9. Learning Curve             N=10→40 | Monotônica: Sim
  🟢 10. SHAP Consonância          3/3 top features alinhadas com Brain Slowing
```

Figura 3. Print do relatório final de integridade gerado pelo notebook.

IX. Discussão

Do ponto de vista metodológico, o pipeline é bem estruturado: remove features absolutas, harmoniza sítios, normaliza por sujeito, avalia por LOSO, testa aleatorização de rótulos, verifica generalização entre sítios e ancora a explicação em SHAP. O ponto crítico está na coexistência de métricas quase perfeitas com sinais de alerta como permutação não significativa e saturação rápida da curva de aprendizado. Em um artigo, o resultado deve ser apresentado como promissor, mas não como prova definitiva de validade clínica sem validação externa independente.

X. Conclusão

O pipeline implementado no notebook analisa EEG de Alzheimer em ReDLat com um fluxo tecnicamente consistente de pré-processamento, harmonização, classificação e auditoria. O conjunto final ficou em 40 sujeitos, 8,795 épocas e 12 features biologicamente motivadas. Random Forest e XGBoost alcançaram desempenho muito alto em LOSO, SHAP apontou coerência neurofisiológica com *brain slowing* e a correlação com MoCA reforçou relevância clínica. Ainda assim, os testes de integridade indicam cautela: a combinação de AUC perfeito, saturation precoce e permutation test não significativo sugere necessidade de validação adicional para excluir artefatos ou confusão residual.

Referências

[1] Tiago Souto Rocha, *BrainLat_dataset_Alzheimer_EEG*, branch `tiago_rocha`, GitHub repository. [Online]. Available: https://github.com/tiagosoutorocha-neuro/BrainLat_dataset_Alzheimer_EEG/tree/tiago_rocha. Accessed: 08-Apr-2026.

[2] T. Souto Rocha, *Pipiline_ML_Alzheimer_3.ipynb*, notebook fornecido pelo usuário e analisado localmente.

[3] W. E. Johnson, C. Li, and A. Rabinovic, "Adjusting batch effects in microarray expression data using empirical Bayes methods," *Biostatistics*, vol. 8, no. 1, pp. 118–127, 2007.

[4] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, 2017.